

Introdução às Redes Neurais Artificiais


Disciplina: Redes Neurais Artificiais

Prof. Dr. Lucas C. Ribas


Programa de Pós-Graduação em Ciência da Computação
Departamento de Ciências de Computação e Estatística
Universidade Estadual Paulista (UNESP)



RNA Timeline: Eventos Chaves




Representação do Neurônio Biológico



- **Dendritos:** Recebem informações (impulsos nervosos) de outros neurônios.
- **Corpo Celular:** Processa as informações recebidas, integrando-as.
- **Axônio:** Transmite as informações processadas para outros neurônios ou células-alvo.
- O fluxo da informação ocorre dos dendritos para o axônio, de maneira unidirecional.

McCulloch & Pitts: O Modelo Matemático de Neurônio Artificial




- Proposto por Warren McCulloch e Walter Pitts em 1943.
- Inspirado no funcionamento básico dos neurônios biológicos.
- Modela o neurônio como uma unidade de processamento binária.
- Capaz de representar funções lógicas básicas como AND, OR e NOT.



Warren McCulloch




Walter Pitts




Perceptron de Rosenblatt (1958)

- Desenvolvido por Frank Rosenblatt em 1958.
- Primeiro modelo de rede neural com capacidade de aprendizado supervisionado.
- Utiliza uma regra de atualização dos pesos baseada no erro de classificação.
- Pode resolver problemas linearmente separáveis
- Limitação: não consegue resolver problemas não-linearmente separáveis (ex.: XOR).



-Rosenblatt, F. (1957). The perceptron, a perceiving and recognizing automaton Project Para. Cornell Aeronautical Laboratory.



-Rosenblatt, Frank. "The Perceptron: A probabilistic model for information storage and organization in the brain." Psychological Review, Vol. 65, No. 6, 1958, pp. 386–408.



Minsky e Papert (1969): O Livro Perceptrons

Minsky & Papert (1969) publicaram o livro *Perceptrons*, destacando limitações fundamentais das redes neurais simples (perceptrons e ADALINEs):


- Demonstraram que perceptrons simples não resolviam problemas não-linearmente separáveis, como o **XOR**.
- Solução para o problema XOR: multicamadas e funções de ativação não lineares. Novos problemas: como treinar?
- Isso gerou ceticismo sobre o futuro das redes neurais.
- Marcou o início do primeiro **"inverno da IA"**, um período de redução significativa de financiamento e pesquisa em RNAs



O Primeiro "Inverno da IA"

- **Crítica aos Perceptrons:** "Se nem conseguem resolver o problema do XOR, por que investir?"
 - ▶ Exageros também contribuíram: promessas de robôs que andavam e falavam nos anos 60.
- Apesar disso, **alguns pesquisadores continuaram** explorando ideias fundamentais.
- **Descobertas importantes** foram feitas nesse período, preparando o caminho para os avanços que temos hoje.

RNA Timeline: Eventos Chaves



Backpropagation

- O algoritmo de **backpropagation** foi formulado de forma independente diversas vezes ao longo da história.
- **Rumelhart, Hinton e Williams (1986)** mostraram que ele realmente funciona, estabelecendo as bases para redes neurais modernas e o aprendizado profundo.
- Esse trabalho impulsionou uma nova era de pesquisas em *redes neurais multicamadas*.
- Posteriormente, foi provado que **redes neurais feedforward** são *aproximadores universais de funções* [2].

Referências:

- 1 Rumelhart, D. E., Hinton, G. E., & Williams, R. J. (1986). *Learning representations by back-propagating errors*. Nature, 323(6088), 533.
- 2 Hornik, K., Stinchcombe, M., & White, H. (1989). *Multilayer feedforward networks are universal approximators*. Neural Networks, 2(5), 359–366.

Mais sobre a origem do algoritmo: <http://people.idsia.ch/~juergen/who-invented-backpropagation.html>

Convolutional Neural Networks (CNNs)

Após a popularização do backpropagation, um avanço importante ocorreu no reconhecimento de imagens, com melhorias para:

- 1 Tornar o treinamento mais eficiente
- 2 Extrair características locais (e capturar dependências espaciais)


Isso foi alcançado com:

- **Compartilhamento de pesos**
- **Camadas de Pooling**

(Origem das CNNs modernas e do uso do dataset MNIST)

Referência histórica:


LeCun, Y., Boser, B., Denker, J. S., Henderson, D., Howard, R. E., Hubbard, W., & Jackel, L. D. (1989). *Backpropagation applied to handwritten zip code recognition*. *Neural Computation*, 1(4), 541–551.



LeCun et al. (1998): LeNet-5 e CNNs modernas

- Em 1998, Yann LeCun et al publicaram o artigo que consolidou o uso de redes convolucionais para reconhecimento de imagens.
- Arquitetura **LeNet-5**, utilizada com sucesso no reconhecimento automático de dígitos manuscritos (dataset MNIST).
- Apesar da baixa capacidade computacional da época, o modelo já era capaz de generalizar bem em tarefas práticas.

LeCun, Y., Bottou, L., Bengio, Y., & Haffner, P. (1998). *Gradient-based learning applied to document recognition*. Proceedings of the IEEE, 86(11), 2278–2324.



LSTMs: Solução para RNNs de Memória Curta

- Redes tradicionais são limitadas: tratam entradas e saídas estáticas, sem noção de tempo.
- RNNs foram propostas para lidar com dados sequenciais (texto, fala, séries temporais), utilizando conexões recorrentes para manter um "estado" entre os passos.
- Porém, RNNs sofrem com o problema de **gradientes que desaparecem ou explodem**, dificultando o aprendizado de dependências longas.
- **Solução: LSTMs**, introduzidas por **Hochreiter & Schmidhuber (1997)**.
 - ▶ Introduzem mecanismos de **memória controlada por portas**.
 - ▶ Permitem aprender **tanto memórias curtas quanto longas**.
 - ▶ Continuam sendo amplamente utilizadas até hoje em NLP, séries temporais e mais.


Referência:

Hochreiter, S., & Schmidhuber, J. (1997). *Long short-term memory*. Neural Computation, 9(8), 1735–1780.

O Segundo "Inverno da IA"

- Até 1998, algoritmos promissores foram propostos:
 - ▶ Backpropagation
 - ▶ LSTMs (Long Short-Term Memory Networks)
 - ▶ CNNs aplicadas a OCR (LeNet)
- Contudo, ao mesmo tempo, as máquinas de vetores de suporte, como **SVMs**, tornaram-se muito populares:
 - ▶ Apresentavam acurácias semelhantes nas mesmas tarefas
 - ▶ Redes neurais não conseguiam ir além de poucas camadas
 - ▶ SVMs ofereciam menos heurísticas e mais fundamentação matemática (teoria da generalização)
- Falta de grandes base de dados
- Além disso, as redes neurais ainda eram caras para treinar
- **Consequência:** mais uma vez, a comunidade de IA se afastou das redes neurais.

RNA Timeline: Eventos Chaves




Hinton et al. (2006): O Renascimento do Deep Learning

- Em 2006, Hinton, Osindero e Teh propuseram um método eficiente para treinar **redes neurais profundas**, introduzindo as **Deep Belief Networks (DBNs)**.
- O problema da época: redes profundas não conseguiam ser treinadas por backpropagation devido ao *vanishing gradient*.
- Contribuições principais:
 - ▶ **Pré-treinamento não supervisionado** camada por camada usando **Restricted Boltzmann Machines (RBMs)**.
 - ▶ Após o pré-treinamento, a rede era ajustada com backpropagation supervisionado.
 - ▶ Demonstraram que redes profundas podem generalizar melhor que modelos rasos (ex: SVM).
- Este trabalho marcou o início da era moderna do **Deep Learning**, mostrando que redes profundas podem ser eficazes e treináveis.

Hinton, G. E., Osindero, S., & Teh, Y. W. (2006). *A fast learning algorithm for deep belief nets*. Neural Computation, 18(7), 1527–1554.

RNA Timeline: Eventos Chaves



Mais dados, mais...

- Em 2009, foi publicado o dataset **ImageNet** [Deng et al., 2009]:
 - ▶ Imagens coletadas para cada termo do WordNet (100.000 classes)
 - ▶ Conceitos organizados em uma **hierarquia semântica**
 - ▶ Ex: “*Ambulance*”, “*Dalmatian dog*”, “*Egyptian cat*”, etc.
 - ▶ Cerca de **16 milhões de imagens** anotadas por humanos
- Surgimento do **ImageNet Large Scale Visual Recognition Challenge (ILSVRC)**:
 - ▶ Subconjunto com **1 milhão de imagens**
 - ▶ **1.000 classes**
 - ▶ Métricas: erro top-1 e top-5
- Este dataset impulsionou o desenvolvimento e comparação de modelos de **aprendizado profundo em larga escala**.



AlexNet e GPUs em cena

- Em 2012, **Krizhevsky, Sutskever e Hinton** reimplementaram uma rede convolucional profunda inspirada no trabalho de LeCun (1998), conhecida como **AlexNet**.
 - ▶ Treinada no **ImageNet**
 - ▶ Utilizou **duas GPUs** para distribuir o treinamento
- Inovações importantes:
 - ▶ **ReLU** no lugar de sigmoid/tanh
 - ▶ **Dropout** para evitar overfitting
 - ▶ **Data augmentation** para melhorar a generalização
- No desafio **ImageNet 2012**, o AlexNet causou um grande impacto:
 - ▶ Obteve **15.4% de erro top-5**, superando amplamente o segundo lugar (26.2%)
 - ▶ A comunidade não esperava redes neurais como candidatas competitivas
- No mesmo período, avanços semelhantes ocorriam no **reconhecimento de fala**, liderados por Hinton e alunos em colaboração com a Microsoft.



AlexNet




Figure 2: An illustration of the architecture of our CNN, explicitly showing the delineation of responsibilities between the two GPUs. One GPU runs the layer-parts at the top of the figure while the other runs the layer-parts at the bottom. The GPUs communicate only at certain layers. The network's input is 150,528-dimensional, and the number of neurons in the network's remaining layers is given by 253,440–186,624–64,896–64,896–43,264–4096–4096–1000.

Tá tudo dominado...

CNN based, non-CNN based

2012 Teams	%error	2013 Teams	%error	2014 Teams	%error
Supervision (Toronto)	15.3	Clarifai (NYU spinoff)	11.7	GoogLeNet	6.6
ISI (Tokyo)	26.1	NUS (singapore)	12.9	VGG (Oxford)	7.3
VGG (Oxford)	26.9	Zeiler-Fergus (NYU)	13.5	MSRA	8.0
XRCE/INRIA	27.0	A. Howard	13.5	A. Howard	8.1
UvA (Amsterdam)	29.6	OverFeat (NYU)	14.1	DeeperVision	9.5
INRIA/LEAR	33.4	UvA (Amsterdam)	14.2	NUS-BST	9.7
		Adobe	15.2	TTIC-ECP	10.2
		VGG (Oxford)	15.2	XYZ	11.2
		VGG (Oxford)	23.0	UvA	12.1

Figures taken from Y. LeCun's CVPR 2015 plenary talk

ILSVRC 2015: A Era das Redes Profundas

- Em 2015, a **Microsoft Research Asia** venceu o **ILSVRC** com uma rede extremamente profunda: **ResNet-152**, com 152 camadas treináveis.
- A rede atingiu uma precisão quase sobre-humana, com apenas **3.5% de erro top-5**:
 - ▶ Em 2016, modelos similares atingiram menos de **3%** de erro.
- Em comparação:
 - ▶ **AlexNet (2012)**: 8 camadas
 - ▶ **GoogLeNet (2014)**: 22 camadas
- O sucesso da **ResNet** mostrou que redes extremamente profundas podiam ser treinadas com eficiência graças aos **atalhos residuais** (skip connections).



He, K., Zhang, X., Ren, S., & Sun, J. (2016). *Deep Residual Learning for Image Recognition*. CVPR.

Avanços em Redes Neurais: Melhorias e Novas Arquiteturas

Rectified Linear Units (ReLU)

Nair, V., & Hinton, G. E. (2010). Rectified linear units improve restricted Boltzmann machines. *ICML*, pp. 807–814.

Dropout

Srivastava, N., Hinton, G., et al (2014). Dropout: A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, **15**(1), 1929–1958.

Transformers

Vaswani, A., et al. (2017). Attention is all you need. *NeurIPS*, pp. 5998–6008.
→ Base dos modelos modernos de NLP e multimodal.

Batch Normalization

Ioffe, S., & Szegedy, C. (2015). Batch Normalization: Accelerating Deep Network Training. *ICML*, pp. 448–456.

GANs (Generative Adversarial Networks).

Goodfellow, I., et al. (2014). Generative adversarial nets. *NeurIPS*, pp. 2672–2680.

Vision Transformers (ViTs)

Dosovitskiy, A., et al. (2020). An image is worth 16x16 words: Transformers for image recognition at scale. *ICLR*.
→ Substitui convoluções por atenção em visão computacional.

Referências

Contém slides baseados em:

- Lecture 1: Introduction to Neural Networks and Deep Learning. UVA DEEP LEARNING COURSE. EFSTRATIOS GAVVES.
- STAT 453: Introduction to Deep Learning and Generative Models. Sebastian Raschka